WARNING: P-hacking

Juan E. Kamienkowski (juank@dc.uba.ar)

Why Most Published Research Findings Are False

John P. A. Ioannidis

loannidis, J. P. (**2005**). Why most published research findings are false. *PLoS medicine*, *2*(8), e124.



P values, the 'gold standard' of statistical validity, are not as reliable as many scientists assume.

THE AMERICAN STATISTICIAN 2016, VOL. 70, NO. 2, 129–133 http://dx.doi.org/10.1080/00031305.2016.1154108

BY REGINA NUZZO

Nuzzo, R. (**2014**). Scientific method: statistical errors. *Nature News*, *506*(7487), 150.

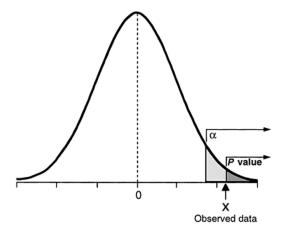
EDITORIAL

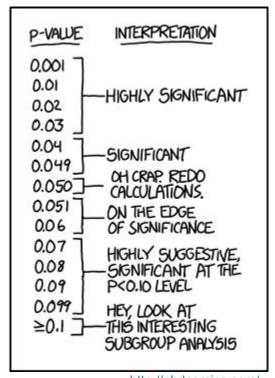
The ASA's Statement on p-Values: Context, Process, and Purpose

Wasserstein, R. L., & Lazar, N. A. (2016). The ASA's statement on p-values: context, process, and purpose. *The American Statistician*, 70(2), 129-133.

Data Mining aplicado a Ciencia y Tecnología 2018

Es la manipulación de los análisis / tests estadísticos con el fin de obtener un resultado significativo (**p < 0.05**). Específicamente se relaciona a cómo se obtiene e informa la significancia estadística.





http://phdcomics.com/

Q: ¿Por qué se enseña la regla "p = 0.05" en tantas universidades?

A: Porque eso es lo que la comunidad científica y los editores de revistas todavía usan.

Q: ¿Por qué tanta gente todavía usa la regla "p = 0.05"?

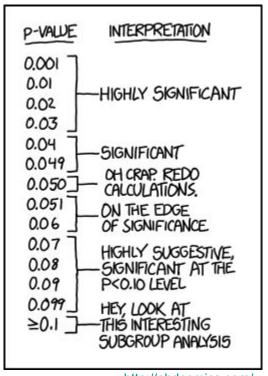
A: Porque eso es lo que se enseña en las universidades.

THE AMERICAN STATISTICIAN 2016, VOL. 70, NO. 2, 129–133 http://dx.doi.org/10.1080/00031305.2016.1154108

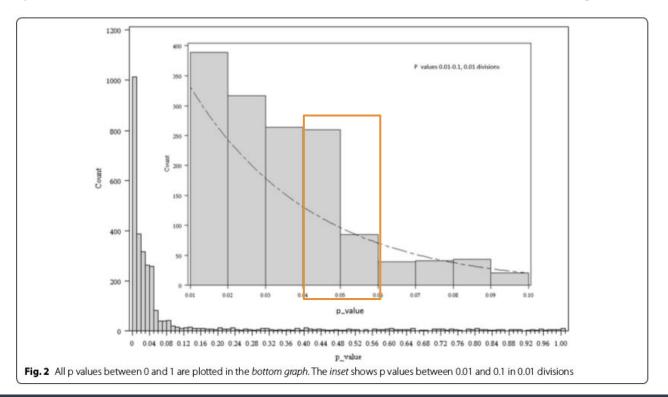
EDITORIAL

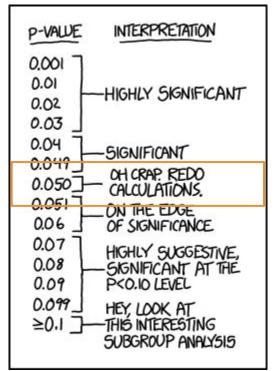
The ASA's Statement on p-Values: Context, Process, and Purpose

Wasserstein, R. L., & Lazar, N. A. (**2016**). The ASA's statement on p-values: context, process, and purpose. *The American Statistician*, *70*(2), 129-133.



http://phdcomics.com/

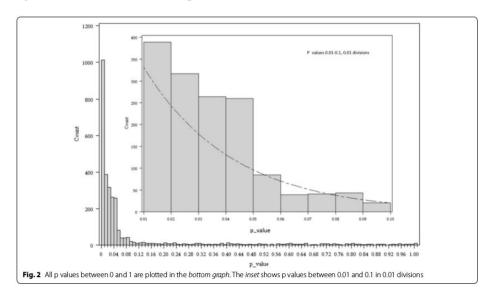


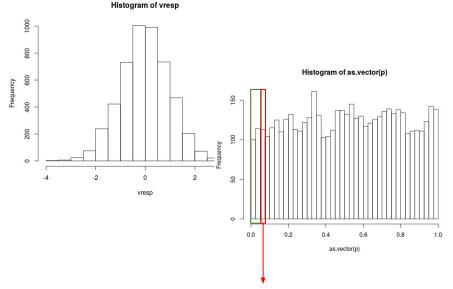


http://phdcomics.com/

Ginsel, B., et al (**2015**). The distribution of probability values in medical abstracts: an observational study. BMC res. notes, 8(1), 721.

¿Cómo se genera esta curva?

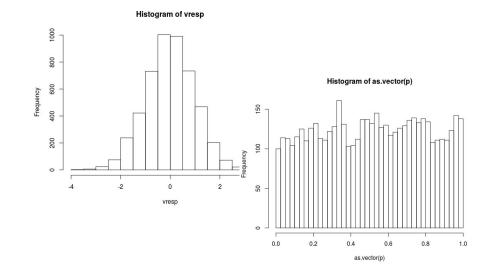




¿Qué pasa si obtengo un resultados con p entre 0.05 y 0.075 y agrego entre algunos ejemplos más? (para decidir si es significativo o no)...

Ahora la probabilidad de caer en los p < 0.05 es del orden del $\sim 25\%$!!!

```
## Ejemplo 1
rm(list = ls())
nreg <- 5000
vresp <- rnorm(nreg, 0, 1)</pre>
hist(vresp)
nsamp = 100
ssamp = 50
vc <- sample(vresp, ssamp, replace = FALSE)</pre>
vresp.df <- data.frame(vc)</pre>
for(i in 2:nsamp){
  vc <- sample(vresp, ssamp, replace = FALSE)</pre>
  vresp.df <- cbind(vresp.df, vc)</pre>
names(vresp.df) <- paste0("muestra", 1:100)</pre>
str(vresp.df)
p <- matrix(NA, nsamp, nsamp)</pre>
for(i in 1:(nsamp-1)){
  for(j in (i+1):nsamp){
    p[i,j]<-t.test(vresp.df[,i],vresp.df[,j])$p.value</pre>
hist(as.vector(p), seq(0,1,by=0.025))
```



```
Histogram of vresp
image(1:nsamp,1:nsamp,p,c(0,1),col=gray.colors(20))
                                                                              1000
ind <- which(p>0.05 & p<0.075, arr.ind = T)
                                                                              800
i <- sample.int(dim(ind)[1],1)</pre>
                                                                                                                           Histogram of as.vector(p)
i1 = ind[i,1]
i2 = ind[i,2]
                                                                              00
p[i1,i2]
                                                                              200
p2 <- matrix(NA, nsamp, 1)</pre>
for(i in 1:nsamp){
                                                                                                                        0.2
  p2[i]<-t.test(c(vresp.df[,i1],sample(vresp, 5,</pre>
                                                        replace = FALSE)),
                  c(vresp.df[,i2],sample(vresp, 5, replace = FALSE)))$p.value
100*sum(p2<0.05)/length(p2)
```

¿Qué pasa si obtengo un resultados con p entre 0.05 y 0.075 y agrego entre algunos ejemplos más? (para decidir si es significativo o no)...

Ahora la probabilidad de caer en los p < 0.05 es del orden del ~25% !!!

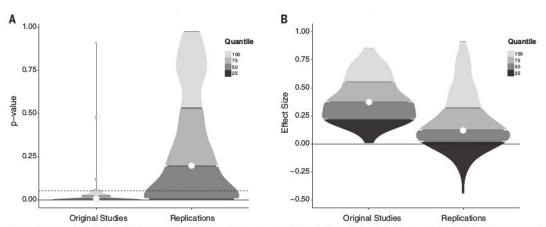


Fig. 1. Density plots of original and replication P values and effect sizes. (A) P values. (B) Effect sizes (correlation coefficients). Lowest quantiles for P values are not visible because they are clustered near zero.

Open Science Collaboration. (2015). Estimating the reproducibility of psychological science. Science, 349(6251), aac4716.

Causas

¿Fraude?
¿Más presión?
¿Más oportunidades?
¿Descuido o desconocimiento?

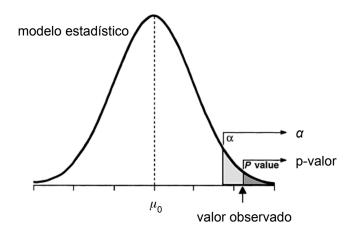
EDITORIAL

The ASA's Statement on p-Values: Context, Process, and Purpose

Wasserstein, R. L., & Lazar, N. A. (**2016**). The ASA's statement on p-values: context, process, and purpose. *The American Statistician*, *70*(2), 129-133.

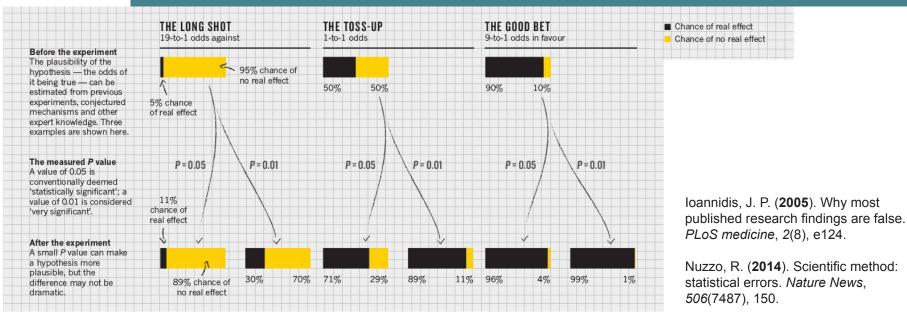
Principios o ¿ Qué es (y qué no) es el p-valor?

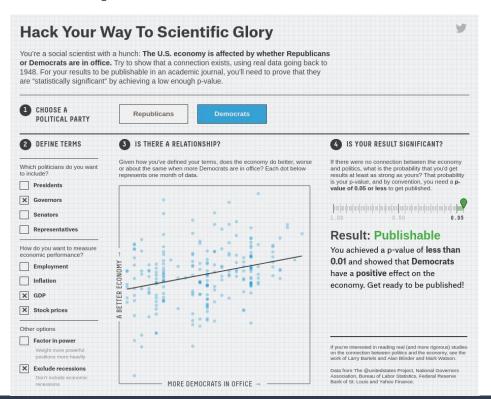
Los p-valores pueden indicar cuán incompatibles son los datos con un modelo estadístico dado.



Wasserstein, R. L., & Lazar, N. A. (2016). The ASA's statement on p-values: context, process, and purpose. *The American Statistician*, 70(2), 129-133.

Los p-valores NO miden la probabilidad de que una hipótesis sea verdadera, o de la probabilidad de que los datos provengan únicamente del azar.





Las conclusiones científicas o políticas NO pueden basarse únicamente en si el p-valor pasa o no un umbral dado.

Wasserstein, R. L., & Lazar, N. A. (**2016**). The ASA's statement on p-values: context, process, and purpose. *The American Statistician*, *70*(2), 129-133.

https://fivethirtyeight.com/features/science-isnt-broken/#part1

Una inferencia apropiada requiere un reporte completo y transparente.

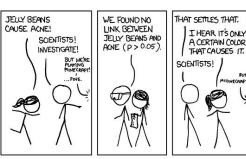
WE FOUND NO

LINK BETWEEN

BEANS AND ACNE

TEAL JELLY

(P>0.05)





WE FOUND NO LINK BETWEEN PURPLE JELLY BEANS AND ACNE (P>0.05) WE FOUND NO LINK BETWEEN SALMON JELLY





WE FOUND NO

LINK BETWEEN

BROWN JELLY

(P>0.05)

BEANS AND ACNE



WE FOUND NO

LINK BETWEEN

WE FOUND NO

LINK BETWEEN

BEANS AND ACNE

PINK JELLY

(P>0.05)



WE FOUND NO

LINK BETWEEN

MAGENTA JELLY

WE FOUND NO

LINK BETWEEN

BEANS AND ACNE

BUE JELLY

(P>0.05)



WE FOUND NO

LINK BETWEEN

YELLOW JELLY





WE FOUND NO

LINK BETWEEN

BEIGE JELLY

WE FOUND NO

LINK BETWEEN

BEANS AND ACNE

GREY JELLY

(P > 0.05).



WE FOUND NO

LINK BETWEEN

WE FOUND NO

LINK BETWEEN

BEANS AND ACNE

(P>0.05)

TAN JELLY





WE FOUND NO

WE FOUND NO

LINK BETWEEN

BEANS AND ACNE

(P>0.05)

CYAN JELLY



WE FOUND NO

WE FOUND A

LINK BETWEEN

GREEN JELLY

(P<0.05)

BEANS AND ACNE



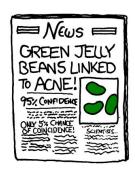
WE FOUND NO

LINK BETWEEN

BEANS AND ACNE

MAUVE JELLY

(P>0.05)



https://xkcd.com/

Wasserstein, R. L., & Lazar, N. A. (2016). The ASA's statement on p-values: context, process, and purpose. The American Statistician, 70(2), 129-133.

Los p-valores pueden indicar cuán incompatibles son los datos con un modelo estadístico dado.

Los p-valores NO miden la probabilidad de que una hipótesis sea verdadera, o de la probabilidad de que los datos provengan únicamente del azar.

Una inferencia apropiada requiere un reporte completo y transparente.

Un p-valor, o significancia estadística, NO mide el tamaño de un efecto o la importancia del resultado.

Por sí mismo, un p-valor NO proveé una buena medida de la evidencia respecto a un modelo o hipótesis.

Wasserstein RL & Lazar NA (2016) "The ASA's Statement on p-Values: Context, Process, and Purpose", The American Statistician, 0:2, 129-133

Conclusiones. "Ningún índice puede sustituir el razonamiento científico."

Buen diseño del estudio y adquisición de datos ("garbage in, garbage out").

Hacer representaciones numéricas y gráficas buenas y variadas.

Comprender el fenómeno estudiado e interpretar los resultados en contexto.

Realizar reportes completos.

Comprender los métodos de análisis utilizados.

Wasserstein RL & Lazar NA (2016) "The ASA's Statement on p-Values: Context, Process, and Purpose", The American Statistician, 0:2, 129-133

Replicar

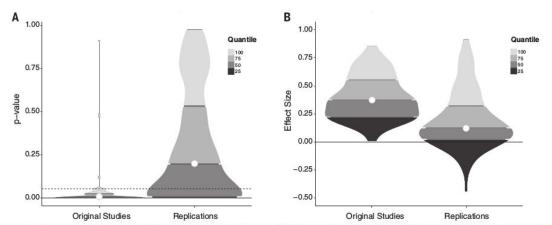


Fig. 1. Density plots of original and replication P values and effect sizes. (A) P values. (B) Effect sizes (correlation coefficients). Lowest quantiles for P values are not visible because they are clustered near zero.

Open Science Collaboration. (2015). Estimating the reproducibility of psychological science. Science, 349(6251), aac4716.

Replicar

Registrar (o pre-registrar) proyectos

http://www.timvanderzee.com/registered-reports/

Replicar Registrar (o pre-registrar) proyectos Fomentar la honestidad en los análisis Documentar, publicar código y datos - Investigación reproducible Ser competente en las técnicas utilizadas



EDITORIAL

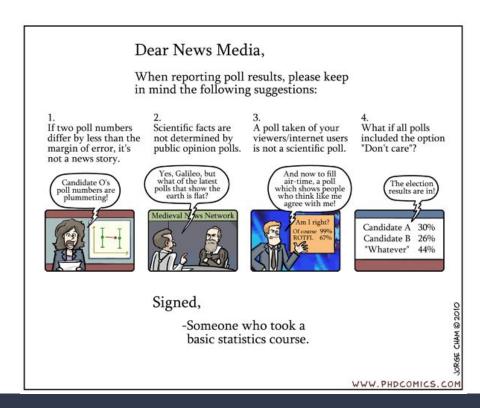
Ten Simple Rules for Effective Statistical Practice

Robert E. Kass¹, Brian S. Caffo², Marie Davidian³, Xiao-Li Meng⁴, Bin Yu⁵, Nancy Reid⁶*

Kass, R. E., Caffo, B. S., Davidian, M., Meng, X. L., Yu, B., & Reid, N. (2016). Ten simple rules for effective statistical practice. PLoS computational biology, 12(6), e1004961.



¿A qué le llamamos p-hacking?



¿A qué le llamamos p-hacking?

CLICKBAIT-CORRECTED P-VALUE:

NULL HYPOTHESIS

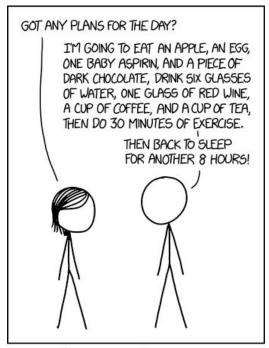
H. ("CHOCOLATE HAS NO EFFECT"
O' ON ATHLETIC PERFORMANCE")

ALTERNATIVE HYPOTHESIS

H.: ("CHOCOLATE BOOSTS
ATHLETIC PERFORMANCE")

FRACTION OF TEST SUBJECTS CLICK(H): WHO CLICK ON A HEADLINE ANNOUNCING THAT H IS TRUE

¿A qué le llamamos p-hacking?



I ONLY DO THINGS THAT NEWS STORIES HAVE SPECIFICALLY TOLD ME TO DO ONCE PER DAY.